机器学习上机实验 05：线性回归-2

实验目标

1. 过拟合直观感知：通过实验观察模型过拟合行为。

2. 非线性特征工程：掌握手动构建多项式基函数的方法，理解如何通过特征变换提升线性模型的表达 力。

3. 正则化调优：学习岭回归（Ridge Regression）中 λ 参数的物理意义

实验环节与任务清单

图像数据标准化 (Data Preparation)

任务 A：编写加载函数，将所有图片缩放为 32x32 灰度图，并进行归一化（除以 255.0），将其展 平为 1024 维向量。狗的标签设为 1，猫的标签设为 0。

具体实现

```
def ld(p):
    x, y = [], []
    for d, l in [('cat', 0), ('dog', 1)]:
        dp = os.path.join(p, d)
        if not os.path.exists(dp): continue
        for f in os.listdir(dp):
            ip = os.path.join(dp, f)
            try:
                # 缩放为32x32灰度图并归一化
                i = Image.open(ip).convert('L').resize((32, 32))
                a = np.array(i) / 255.0
                x.append(a.flatten()) # 展平为1024维向量
                y.append(l)
            except: pass
    return np.array(x), np.array(y)
```

线性模型基准测试 (Linear Baseline)

任务 A

```
# 3.2 任务A: 构建包含偏置项的设计矩阵 X
b1, b2 = np.ones((x1.shape[0], 1)), np.ones((x2.shape[0], 1))
x1_1, x2_1 = np.hstack((b1, x1)), np.hstack((b2, x2)) # 1次项
```

```
# 3.2 线性模型基准测试 - 任务A
def slv(x, y, l):
    n = x.shape[1]
    i = np.eye(n)
    i[0, 0] = 0 # 偏置项不参与正则化
    w = np.linalg.inv(x.T @ x + l * i) @ x.T @ y
    return w
```

任务 B

```
# 3.2 线性模型基准测试 - 任务B
def ac(x, y, w):
    p = x @ w
    c = (p >= 0.5).astype(int) # 阈值设为0.5
    return np.mean(c == y)
```

```
Lambda: 1.00e-06
  1次项 - 训练集准确率: 1.0000, 验证集准确率: 0.4900
```

多项式基函数扩展

任务 A 手动实现 2 次项（平方项）特征映射，将特征维度扩展至 $1024 \times 2 + 1 = 2049$ 维。

```
# 3.3 多项式基函数扩展 - 任务A
def pl(x):
    # 手动实现2次项(平方项)特征映射，扩展至2048维
    return np.hstack((x, x**2))
```

任务 B：对比 1 次、2 次项在验证集上的准确率变化，分析引入非线性项是否缓解了欠拟合。

```
Lambda: 1e-06
  1次项 - 训练集准确率: 1.0000, 验证集准确率: 0.4900
  2次项 - 训练集准确率: 1.0000, 验证集准确率: 0.5500
```

答：引入 2 次项特征映射（维度扩展至 2049 维）使得模型能够捕捉到像素间的二阶相关性 。虽然训练集依然维持在 1.0 的过拟合状态，但验证集表现的提升说明非线性特征在一定程度上缓解了线性模型表达力不足的问题。

正则化强度扫描

经过多次实验调整，选取 lanmda 个数为 15 个，一个为 1e-6,其余处于 1e-3 到 15 之间。

实验结果如下：

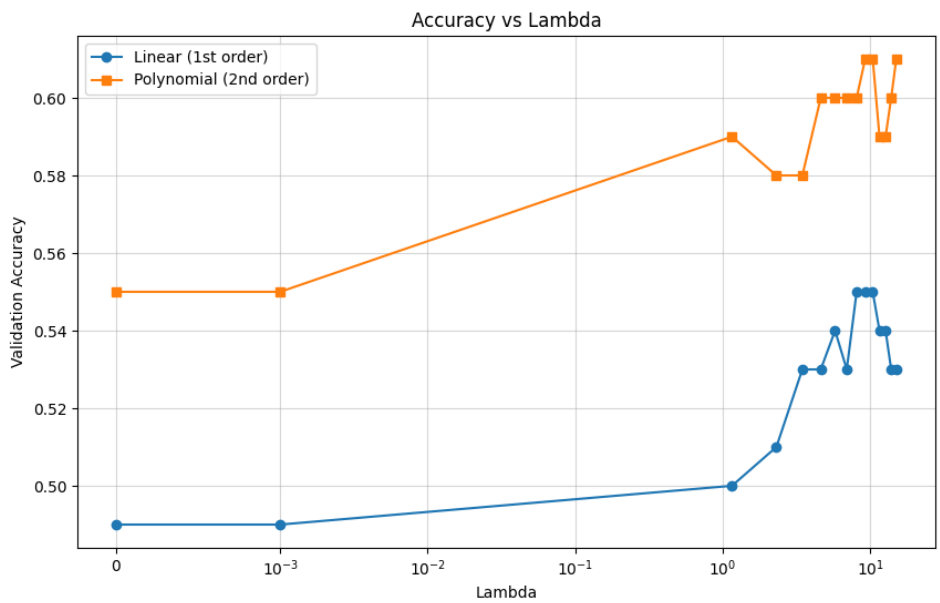

从中可以观察到，lamda 的最佳取值在 9.23 到 10 之间。适当增大正则化强度能显著抑制由于特征维度过高带来的过拟合，提高模型在未知数据上的稳定性

权重分布可视化 (Weight Visualization)

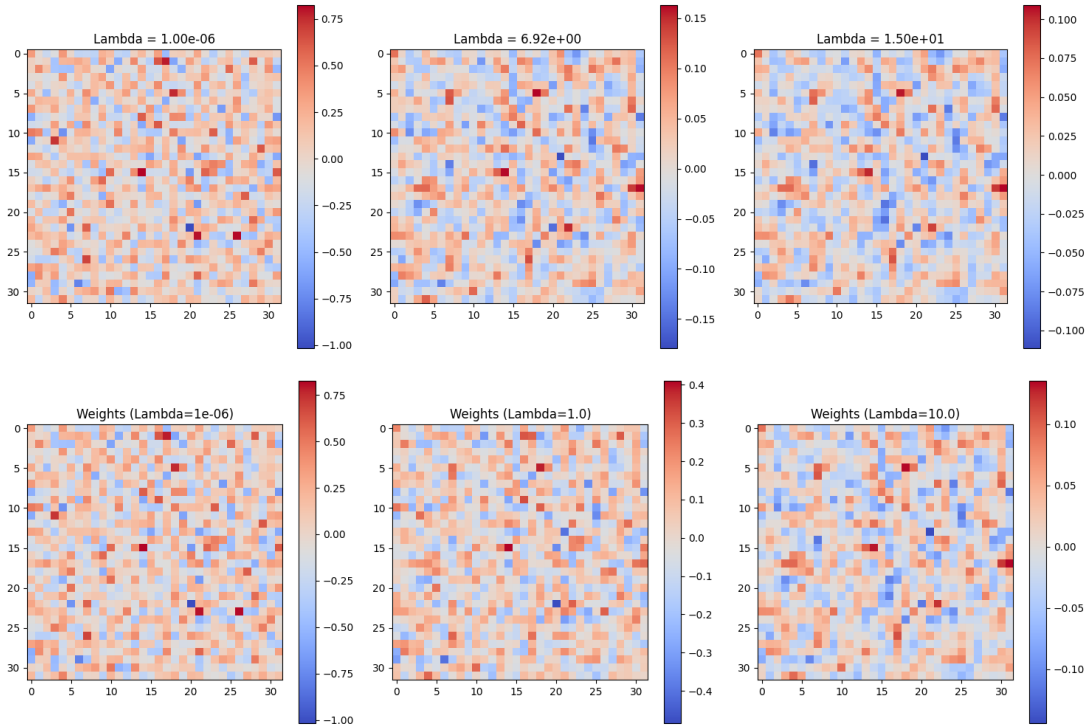

答：**弱正则化（\lambda = 1.00e-06）**：权重图表现为极其凌乱、高对比度的“椒盐噪声”状点阵。这证实了模型在尝试捕捉**局部像素噪声**，导致泛化性极差。

强正则化（\lambda = 1.50e+01）：权重分布变得更加平滑且数值范围显著缩小（从 ± 0.75 缩小至约 ± 0.1）。图中开始出现一些模糊的成块结构，说明模型正在摆脱对单个孤立噪声像素的依赖，转而尝试捕捉物体的**轮廓特征或区域规律** 。