机器学习上机实验06：线性回归-3

实验目标

1. 数值稳定性直观感知：通过构造共线性数据，观察正规方程在处理奇异矩阵时的失效现象。
2. SVD 几何意义理解：通过坐标变换可视化，掌握奇异值分解中旋转与拉伸的物理含义。
3. 矩阵病态性分析：学习条件数概念，理解观测噪声如何在高共线性场景下被放大，并掌握岭回归的 缓解机制。

实验环节

(Singularity & Ridge)

任务 A：构造共线性设计矩阵： 利用 `numpy` 构造100×3的矩阵 X，确保第三列 x_3 严格等于前两列之和。设定真实系数 $w = [1, 2, 3]$ 生成标签 y。

```
def build_collinear_data(n=100, seed=42):
    rng = np.random.default_rng(seed)
    x1 = rng.normal(size=n)
    x2 = rng.normal(size=n)
    x3 = x1 + x2  # 严格线性相关

    X = np.column_stack([x1, x2, x3])
    w_true = np.array([1.0, 2.0, 3.0])
    y = X @ w_true
    return X, y, w_true
```

任务B：算法对比

```
def normal_equation_inverse(X, y):
    """
    正规方程：w = (X^T X)^(-1) X^T y
    当 X^T X 奇异时，这里会报错。
    """
    XtX = X.T @ X
    Xty = X.T @ y
    w = np.linalg.inv(XtX) @ Xty
    return w

def ridge_regression_closed_form(X, y, lam=1e-3):
    """
    岭回归闭式解：
    w = (X^T X + λI)^(-1) X^T y
    """
    n_features = X.shape[1]
    XtX = X.T @ X
    Xty = X.T @ y
    w = np.linalg.solve(XtX + lam * np.eye(n_features), Xty)
```

```
    return w
```

算法求解分别为正规方程和岭回归。

实验结果：

```
正规方程求得的 w = [12.518149 13.651815 -5.651815]
rank(X) = 2
rank(X^T X) = 2

正规方程求得的 w = [12.518149 13.651815 -5.651815]

正规方程求得的 w = [12.518149 13.651815 -5.651815]
与真实系数的 MSE = 114.42881282308458
与真实系数的 MSE = 114.42881282308458
正规方程误差范数 ||w - w_true||_2 = 18.52799067544168


岭回归 (lambda=0.001) 求得的 w = [0.999997 1.999991 2.999989]
岭回归 (lambda=0.001) 求得的 w = [0.999997 1.999991 2.999989]
与真实系数的 MSE = 7.060605796590223e-11
岭回归误差范数 ||w - w_true||_2 = 1.4553974505189525e-05
```

现象:

在构造严格共线性数据（$x_3 = x_1 + x_2$）后，设计矩阵秩下降；

正规方程：得到明显偏离真实值 $[1, 2, 3]$ 的异常解
岭回归仍能得到稳定解，且与真实系数接近

原因:

共线性导致：

$$X^T X \text{ 不可逆（奇异矩阵）}$$

正规方程依赖矩阵求逆，因此数值不稳定；岭回归通过引入正则项：

$$X^T X + \lambda I$$

使矩阵变为正定，从而恢复可逆性。

结论:

共线性会导致线性回归解的不唯一性与数值不稳定，正规方程在该情况下不可靠，岭回归通过正则化有效提高求解稳定性，是处理共线性问题的常用方法。

Geometric Interpretation of SVD

任务A：

```
    # SVD 分解: A = U @ S @ Vt
    U, s, Vt = np.linalg.svd(A)
    S = np.diag(s)
```

```
# 依次变换
    circle_vt = Vt @ circle
    circle_s = S @ circle_vt
    circle_u = U @ circle_s
```

实验结果如下：

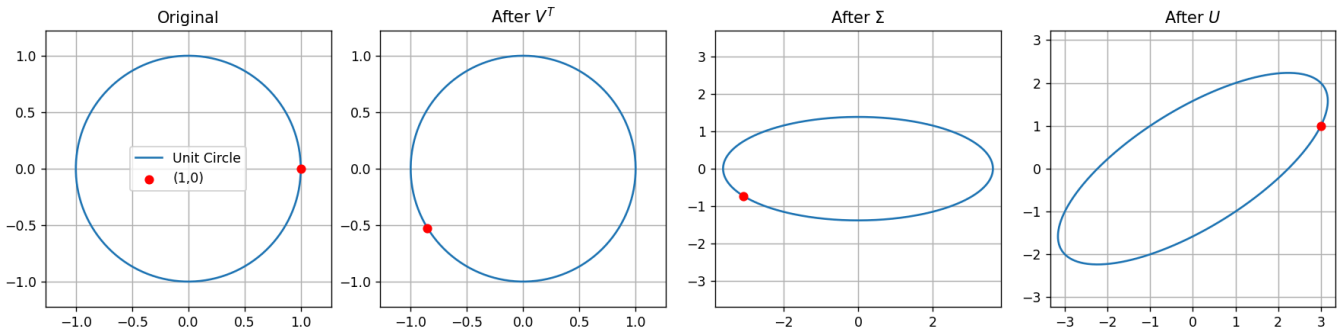


```
起始点 p0 = [1. 0.]
经过 V^T 后 p1 = [-0.850651 -0.525731]
经过 Σ 后 p2 = [-3.077684 -0.726543]
经过 U 后 p3 = [3. 1.]
直接计算 A p0 = [3. 1.]
```

红点轨迹分析：

现象
单位圆在变换过程中经历：

保持形状但发生旋转

被拉伸为椭圆

再次旋转形成最终形状

起始点 $(1,0)$ 的轨迹表现为方向变化与长度变化的叠加

原因:
SVD 分解：

$$A = U\Sigma V^T$$

对应三个几何操作：
V^T：对输入空间进行旋转
Σ：沿主轴方向进行缩放（由奇异值决定）
U：对结果再进行旋转
结论
任意线性变换均可分解为“旋转 + 缩放 + 旋转”,奇异值刻画了不同方向上的伸缩程度

病态问题与条件数分析 (Condition Number & Stability)

任务A:

构造病态矩阵

```
def build_ill_conditioned_data(n=100, seed=7, eta=1e-8):
    rng = np.random.default_rng(seed)
    x1 = rng.normal(size=n)
    x2 = x1 + eta * rng.normal(size=n)
    x3 = x1 + x2 + eta * rng.normal(size=n)

    X = np.column_stack([x1, x2, x3])
    w_true = np.array([1.0, 2.0, 3.0])
    y = X @ w_true
    return X, y, w_true
```

条件数分析

```
    s_X = np.linalg.svd(X, compute_uv=False)
    s_XtX = np.linalg.svd(XtX, compute_uv=False)

    cond_X = s_X[0] / s_X[-1]
    cond_XtX = s_XtX[0] / s_XtX[-1]
```

任务B

无噪声基准

```
    try:
        w_clean = normal_equation_solution(X, y)
        print("无噪声标签下，正规方程解 w_clean =", w_clean)
        print("||w_clean - w_true||_2 =", np.linalg.norm(w_clean - w_true))
    except np.linalg.LinAlgError as e:
        print("无噪声情况下正规方程失败：", e)
```

有噪声

```
rng = np.random.default_rng(123)
    noise_level = 1e-4
    y_noisy = y + noise_level * rng.normal(size=y.shape)

    try:
        w_noisy = normal_equation_solution(X, y_noisy)
        print("加入噪声后，正规方程解 w_noisy =", w_noisy)
        print("||w_noisy - w_true||_2 =", np.linalg.norm(w_noisy - w_true))
        print("||w_noisy - w_clean||_2 =", np.linalg.norm(w_noisy - w_clean))
    except np.linalg.LinAlgError as e:
        print("加入噪声后正规方程失败：", e)
```

任务C

岭回归稳定性的验证：

```
lam = 1e-3
w_ridge_clean = ridge_solution(X, y, lam=lam)
w_ridge_noisy = ridge_solution(X, y_noisy, lam=lam)
```

实验结果：

```
X 的奇异值 = [21.85428838  0.00000006  0.00000006]
X 的条件数 cond(X) = 385042425.4907103
X^T X 的奇异值 = [477.6099207   0.          0.        ]
X^T X 的条件数 cond(X^T X) = 4.913123197676109e+16
理论上，cond(X^T X) 约等于 cond(X)^2
cond(X)^2 = 1.482576694277692e+17

无噪声标签下，正规方程解 w_clean = [-9.00000001 -4.         11.        ]
||w_clean - w_true||_2 = 14.142135628293197

加入噪声后，正规方程解 w_noisy = [  46.99998787 -132.          47.        ]
||w_noisy - w_true||_2 = 148.35093152540045
||w_noisy - w_clean||_2 = 144.27750567107356

岭回归 (lambda=0.001) 无噪声解 = [1.49999686 1.49999686 2.99999372]
||w_ridge_clean - w_true||_2 = 0.707106780694691

岭回归 (lambda=0.001) 噪声解 = [1.49999484 1.49999484 2.99998968]
||w_ridge_noisy - w_true||_2 = 0.7071067832576855
||w_ridge_noisy - w_ridge_clean||_2 = 4.950390022094086e-06
```

结论：当X接近共线时，X^TX的条件数会显著增大，这会放大标签噪声对参数估计的影响；岭回归通过正则化通常能显著缓解这一问题。